CUET PG

DAILY CLASS NOTES

Computer Science

Digital Fundamental

Lecture – 04

Floating Point Representation



Floating Point Representation

Content:

Floating Point Representation – Introduction, Structure, Importance, Precision Types: Single & Double Precision, Difference Between Single & Double Precision, Bias, Range & Usage Comparison, Resource Use & Cost Difference**.**

Floating Point Representation– Introduction:

- Floating point is used to store very big or very small real numbers.
- It works like scientific notation.
- Number is stored as:

  Value = Sign × Significand × Base^ Exponent
- Component:
  - Sign: + or –
  - Significand (Mantissa): Holds precision (real digits)
  - Base: usually 2 in binary
  - Exponent: decides how large or small the number becomes

Why is floating point used?

- Used in scientific computing, graphics, machine learning, etc.
- Helps store real numbers with a balance of range + precision.
- Helps represent real numbers efficiently.

Precision Types: Single & Double Precision:

Single Precision (32-bit)	**Double Precision (64-bit)**
Base = 2	Base = 2
Sign = 1 bit	Sign = 1 bit
Exponent = 8 bits	Exponent = 11 bits
Mantissa = 23 bits + 1 hidden bit	Mantissa = 52 bits + 1 hidden bit
Also called FP32 / Binary 32	Also called FP64 / Binary 64
Used for applications where some approximation is acceptable.	Used when higher accuracy is required.

Single precision (32-bit)

Sign	Exponent	Mantissa
1 bit	8 bit	23 bit

Double Precision(64- bit)

Sign	Exponent	Mantissa
1 bit	11 bit	52 bit

Difference Between Single & Double Precision:

Single Precision	Double Precision
Faster, less accurate.	Slower but more accurate.
Requires fewer resources	Uses more memory + computation power.
Used in games, simple applications.	Used in scientific calculators, complex programs.
Bias = 127	Bias = 1023
Range = $\mathbf{2^{-126}}$ **to** $\mathbf{2^{+127}}$	Range = $\mathbf{2^{-1022}}$ **to** $\mathbf{2^{+1023}}$
Used where precision matters less.	Used where precision matters more.

Cost & Resource Usage:

Single Precision	Double Precision
Requires fewer resources.	More accurate but uses more memory and processing power.
Less expensive.	Cost does not justify using it for all computations.
Suitable for wide representation but not highly accurate tasks.	

फ़्लोटिंग पॉइंट प्रतिनिधित्व

विषय-वस्तु:

प्लावी बिंदु निरूपण – परिचय, संरचना, महत्व, परिशुद्धता के प्रकार: एकल परिशुद्धता और द्वि-परिशुद्धता, एकल और द्वि-परिशुद्धता के बीच अंतर, अभिनति, रेंज (परास) और उपयोग का तुलनात्मक अध्ययन, संसाधन उपयोग और लागत में अंतर।

फ्लोटिंग पॉइंट निरूपण - परिचय

- प्लावी बिंदु का उपयोग अत्यधिक बड़ी या अत्यधिक छोटी वास्तविक संख्याओं को संग्रहीत करने के लिए किया जाता है।
- यह वैज्ञानिक संकेतन की तरह कार्य करता है।
- संख्या का निरूपण
- संख्या को इस प्रकार संग्रहीत किया जाता है:
  मान = चिह्न(साइन) × सार्थक अंक × आधार^घातांक(एक्स्पोनन्ट)
- घटक:
  - चिह्न : + or –
  - सार्थक अंक (मंटिसा): परिशुद्धता (वास्तविक अंक) रखता है
  - आधार: बाइनरी में आमतौर पर 2
  - घातांक: यह तय करता है कि संख्या कितनी बड़ी या छोटी होगी

फ्लोटिंग पॉइंट का उपयोग क्यों किया जाता है?

- वैज्ञानिक कंप्यूटिंग, ग्राफ़िक्स, मशीन लर्निंग आदि में उपयोग किया जाता है।
- रेंज + प्रिसिजन के संतुलन के साथ वास्तविक संख्याओं को संग्रहीत करने में मदद करता है।
- वास्तविक संख्याओं को कुशलतापूर्वक प्रस्तुत करने में मदद करता है।

प्रिसिजन (परिशुद्धता) प्रकार: एकल (सिंगल) और दोहरी परिशुद्धता:

सिंगल प्रिसिजन (32-बिट)	**डबल प्रिसिजन (64-बिट)**
आधार = 2	आधार = 2
चिह्न = 1 बिट	चिह्न = 1 बिट
घातांक = 8 बिट्स	घातांक = 11 बिट्स
मंटिसा = 23 बिट्स + 1 छिपा हुआ बिट	मंटिसा = 52 बिट्स + 1 हिडन बिट
इसे FP32 / बाइनरी 32 भी कहा जाता है	इसे FP64 / बाइनरी 64 भी कहा जाता है
उन अनुप्रयोगों के लिए उपयोग किया जाता है जहां कुछ सन्निकटन स्वीकार्य है।	जब उच्च सटीकता की आवश्यकता होती है तब इसका उपयोग किया जाता है।

सिंगल प्रिसिजन (32-बिट)

चिह्न	घातांक	मंटिसा
1 बिट	8 बिट	23 बिट

डबल प्रिसिजन (64-बिट)

चिह्न	घातांक	मंटिसा
1 बिट	11 बिट	52बिट

सिंगल और डबल प्रिसिजन के बीच अंतर:

सिंगल प्रिसिजन	**डबल प्रिसिजन**
तेज़, कम सटीक	धीमी लेकिन अधिक सटीक
कम संसाधनों की आवश्यकता होती है	अधिक मेमोरी + कम्प्यूटेशन शक्ति का उपयोग करता है।
खेलों, सरल अनुप्रयोगों में उपयोग किया जाता है।	वैज्ञानिक कैलकुलेटर, जटिल कार्यक्रमों में उपयोग किया जाता है।
बायस = 127	बायस = 1023
रेंज = 2^{-126} to 2^{+127}	रेंज = 2^{-1022} to 2^{+1023}
इसका उपयोग वहां किया जाता है जहां प्रिसिजन कम मायने रखती है।	इसका उपयोग वहां किया जाता है जहां प्रिसिजन अधिक मायने रखती है।

लागत एवं संसाधन उपयोग:

सिंगल प्रिसिजन	**डबल प्रिसिजन**
कम संसाधनों की आवश्यकता है।	अधिक सटीक लेकिन अधिक मेमोरी और प्रसंस्करण शक्ति का उपयोग करता है।
कम महंगा।	लागत के कारण सभी गणनाओं के लिए इसका उपयोग करना उचित नहीं है।
व्यापक प्रतिनिधित्व के लिए उपयुक्त लेकिन अत्यधिक सटीक कार्यों के लिए नहीं।	

